

Unidade Curricular de Detecção Remota  
Aplicada ao Ordenamento do Território  
Mestrado de Sistemas de Informação Geográfica e Ordenamento do  
Território

# Relatório Prático

Docente  
Lia Bárbara Cunha Barata Duarte

Discente:  
Tiago Manuel Gonçalves Brito  
Ano Letivo- 2023/2024

## Índice

1- Introdução e objetivos.....	3
2- Caracterização da Área em Estudo.....	4
3- Metodologia.....	5
4-Resultados .....	6
4.1- Cálculo do NDVI .....	6
.....	8
4.2- Classificação Supervisionada .....	9
4.2.1- Classificação supervisionada da imagem de verão .....	10

4.2.2- Classificação supervisionada da imagem de inverno .....	11
4.3- Avaliação da Exatidão da imagem .....	12
4.3.1- Precisão geral da classificação supervisionada de verão .....	13
4.3.1- Precisão geral da classificação supervisionada de Inverno.....	14
Conclusão:.....	15
Bibliografia .....	16
Anexos:.....	16

## **1- Introdução e objetivos**


Este trabalho foi realizado no âmbito da unidade curricular de Detecção Remota Aplicada ao Ordenamento do Território, do mestrado de Sistemas de Informação Geográfica e Ordenamento do Território. Este trabalho apresenta algumas das capacidades ligadas à utilização das ferramentas de deteção remota no SIG, mostramos desde os princípios físicos, às características dos programas e os seus exemplos de aplicação, isto é, como analisar e organizar os dados e a importância da validação dos resultados.

A deteção Remota consiste no processo de adquirir informação sobre objetos, fenómenos ou áreas sem que haja contacto direto com os mesmos, geralmente utiliza-se um sensor de radiação eletromagnética colocado acima desta superfície. (Jensen, J.R., 2006)

O Sentinel é um satélite que pertence ao programa Copernicus, tendo como modelo mais recente o Sentinel 6. Este apresenta dados referentes às imagens de radar do oceano e da Terra, imagens óticas MR, altimetria e radar para uso dos serviços marinhos e terrestres, apresenta também domínios de monitorização da atmosfera. O satélite 2-A que é o utilizado para este estudo, foi lançado no ano de 2015 é constituído por 13 bandas (4 bandas com resolução de 10 m, 6 bandas com resolução de 20m e 3 bandas com resolução de 60m).

## 2- Caracterização da Área em Estudo

O concelho é limitado a oeste pela Espanha e pelo município de Melgaço, a norte pelos municípios de Melgaço e Monção, a este pelos municípios de Paredes de Coura e Ponte de Lima e a Sul pelo município de Ponte da Barca (Figura 1).



Freguesias	Abreviações:	Freguesias	Abreviações:
Aboim das Choças (1)	AC	Paço	PA
Aguiã	AG	Padroso	PAD
Azere	AZ	Prozelo	PR
Cabana Maior	CM	Rio Frio	RF
Cabreiro	CAB	Rio de Moinhos	RM
Cendufe	CE	Sabadim	SAB
Couto	CO	Jolda (S. Paio)	JSP
Gavieira	GAV	Senharei	SE
Gondoriz	GON	Sistelo	SIS
Miranda	MI	Soajo	SOA
Monte Redondo	MR	Vale	VA
Oliveira	OL	União das Freguesias de Eiras e Mei	EM
Freguesias	Abreviações:		
União das Freguesias de Alvora e Loureda	AL		
União das Freguesias de Arcos De Valdevez (São Paio) e Gieia	SPG		
União das Freguesias de Arcos De Valdevez (Salvador), Vila Fonche e Parada	SVF		
União das Freguesias de Grade e Carralcova	GC		
União das Freguesias de Guilhadeses e Santar	GS		
União das Freguesias de Jolda (Madalena) e Rio Cabrão	JRC		
União das Freguesias de Padreiro (Salvador e Santa Cristina)	PD		
União das Freguesias de Portela e Extremo	PR		
União das Freguesias de São Jorge e Ermelo	SJE		
União das Freguesias de Souto e Tabaço	ST		
União das Freguesias de Távora (Santa Maria e São Vicente)	TA		
União das Freguesias de Vilela, São Cosme e São Damião e Sá	VSC		

Figura 2- Tabela das freguesias representadas no mapa de enquadramento

### 3- Metodologia

Para a elaboração e análise de diferentes tipos de imagens e dados criados, foi necessário realizar alguns processos para atingir os objetivos pretendidos. Este projeto prático iniciou-se com a escolha de uma área de estudo, que posteriormente seria exportada da CAOP 2022 (Carta Administrativa Oficial de Portugal), obtendo assim os limites da área de estudo e as bases para o enquadramento geográfico.

Num segundo momento, foi necessário selecionar e fazer o download das duas imagens do satélite Sentinel 2-A, relativas ao programa Copernicus, disponíveis no site do Copernicus Open Access Hub, para dois dias diferentes no ano representando assim duas estações diferentes (verão e inverno). As datas escolhidas foram o dia 9 de outubro (inverno) e 13 de julho (verão) do ano de 2023.

Após o download das imagens, procedeu-se ao tratamento das imagens no software QGIS, onde como referido anteriormente se exportou a área de estudo com recurso à ferramenta “select by attributes”.

Dando seguimento aos passos anteriores, com o auxílio do software QGIS, foi realizado o cálculo do índice ambiental (NDVI) para as duas datas escolhidas, tendo por objetivo uma análise das principais características da área de estudo ao nível da cobertura vegetal durante duas épocas diferentes do ano. Para o cálculo do NDVI, tivemos de utilizar a ferramenta do QGIS “Calculadora raster” onde inserimos a banda infravermelha próxima (NIR) (banda 8 do Sentinel-2) e a banda vermelha (RED) (banda 4 do Sentinel-2) para efetuar a seguinte fórmula para o cálculo  $NDVI = (BNIR - BVermelho) / (BNIR + BVermelho)$ .

Houve também o trabalho adicional de definir classes, passando a ter cada índice, classes compreendidas entre os mesmos valores, possibilitando assim a criação de pontos de comparação e intervalos semelhantes. Do mesmo modo, foram definidas cores associadas às classes e aos índices, tentando-se assim uniformizar e adaptar as mesmas àquilo que definiam, de forma a facilitar a leitura e compreensão das imagens.

A segunda parte do trabalho consistiu na classificação supervisionada da imagem, para isso foi necessário recorrer ao Plugin do QGIS Semi-Automatic Classification Plugin, de modo a realizar o pré processamento, sendo fundamental para aplicar as correções atmosféricas através do método DOS1. Em seguida criou-se um raster virtual, que nos mostra as diferenças que a ferramenta RGB, nos disponibiliza, permitindo-nos realizar diferentes combinações de cor entre três bandas, possibilitando-nos destacar alguns elementos.

Após definir que a melhor combinação para o nosso objetivo é 7-3-2, criamos o ROI e após isso criamos a macro classe e depois criamos a classe e definimos as áreas de treino, entre seis a sete áreas de treino para cada classe, repetiu-se o processo até ter as áreas de treino para todas as classes.

No fim de criar as áreas de treino, passamos para a classificação supervisionada. No processamento de bandas, utilizando as classes que tinham sido criadas inicialmente anteriormente correspondem a uma classificação credível. Depois fez-se o processamento das bandas utilizando as classes criadas e definindo o algoritmo de classificação de cada vez (Maximum Likelihood, Minimum distance e Spectral Angle Mapping). Feitas as classificações procedeu-se ao pós-processamento para calcular o accuracy que nos daria a matriz de erro para cada algoritmo utilizado tendo como objetivo obter um overall accuracy acima de 75%. Após ter tudo calculado criou-se a cartografia referente às classificações feitas anteriormente para verão e inverno para os três algoritmos.

## 4-Resultados

### 4.1- Cálculo do NDVI

O Normalized Difference Vegetation Index (NDVI) é um índice de vegetação, que resulta do cálculo da seguinte fórmula:  $NDVI = \frac{\text{BandaNIR} - \text{BandaVermelho}}{\text{BandaNIR} + \text{BandaVermelho}}$ . O resultado deste varia entre -1 (ausência de vegetação) e 1 (elevada densidade de vegetação ativa). Os valores mais elevados demonstram que existe uma grande diferença entre a radiação vermelha (RED) e a radiação infravermelha próxima (NIR), devido à elevada refletância que a vegetação fotossinteticamente ativa apresenta. Os valores mais baixos do NDVI significam que existe pouca diferença entre as bandas do infravermelho próximo (NIR) e as bandas do vermelho (RED), porque há pouca atividade fotossintética ou porque há muito pouca refletância da banda infravermelha próxima (NIR) (ou seja, a água reflete muito pouco o NIR).

Os resultados obtidos da imagem correspondente a um dia de inverno, dia 9 de outubro estão representados na Figura 4 enquanto os resultados obtidos da imagem de um dia de verão, dia 13 de julho estão representados na Figura 3.

Os valores obtidos no NDVI de verão vão de encontro aos valores esperados, visto que existe uma maior atividade fotossintética da vegetação no verão. Estes resultados acontecem porque no verão a quantidade de radiação que chega à Terra é maior em relação ao inverno, proporcionando uma atividade fotossintética mais elevada. O maior valor obtido no NDVI de verão é 1 e o menor valor foi -1.

Os valores da classe -1 a 0 (azul) correspondem aos corpos de água, neste caso o Rio Lima e o Rio Vez. Estes valores ocorrem devido à grande absorção que a água tem sobre a banda no NIR e por isso apresenta valores nulos.

A classe 0 – 0,2 (vermelho) corresponde às construções, solo nu e pequenos corpos de água, como o centro da vila de Arcos de Valdevez e a rocha nua na Serra da Peneda. Os valores justificam a grande absorção de banda do NIR, mas apresentando alguma refletância da banda vermelha, não apresentando valores nulos como os corpos de água.

A classe 0,2 – 0,4 (verde-claro) corresponde a zonas com pouca vegetação e as áreas de vegetação mais seca. Por ser vegetação, já apresenta maiores valores de refletância da banda do NIR, mas devido a estar meia seca apresenta pouca refletância.

A classe 0,4 – 0,6 (verde) é a classe que predomina em todo o município e representa áreas agrícolas, matos e algumas zonas com árvores.

A classe 0,6 – 1 (verde-escuro) apresenta a vegetação saudável e que está mais fotossinteticamente ativa, é composta por áreas de floresta.

Os valores obtidos no NDVI de inverno são como os previstos, pois existe uma menor atividade fotossintética da vegetação no inverno. Estes resultados acontecem porque O maior valor obtido no NDVI de inverno é 0,69 e o menor valor foi é -0,20.

Os valores que se observam podem ser justificados ao facto de no inverno ser uma época de maior precipitação o que permite á vegetação renovar-se e manter-se saudável, além disso nesta época é quando cresce mais vegetação rasteira o que vai levar ao aumento da reflexão do NIR. Os valores mais baixos podem ser explicados pelo facto da vegetação não ser a indicada da estação, neste caso as arvores de folha caduca que perdem as suas copas no inverno levando a uma menor reflexão da radiação e permitindo que haja uma maior refletância da luz vermelha das edificações e de espaços sem vegetação ou com rocha nua.

Comparando as figuras 3 e 4 podemos observar que os valores da classe 0,6 a 1 são muito maiores na imagem de verão enquanto na imagem de inverno são quase impercetíveis. Ou conclusão que é possível ver é que os valores das classes 0 a 0,2 que representam as áreas artificializadas e os espaços sem vegetação e rocha nua estão muito mais visíveis no NDVI de inverno do que no NDVI de verão.

Outra diferença que é possível ver nas duas imagens é nas classes predominantes no NDVI de verão predominam as classes 0,4 a 0,6 e 0,6 a 1 são as classes que mostram que a vegetação está mais saudável e logo está mais fotossinteticamente ativa em contrapartida no NDVI de inverno as classes que predominam são 0,2 a 0,4 e 0,4 a 0,6 que são as classes em que a vegetação está menos saudável, é de ressaltar que as áreas da classe de vetação mais saudável são quase impercetíveis no NDVI de inverno.

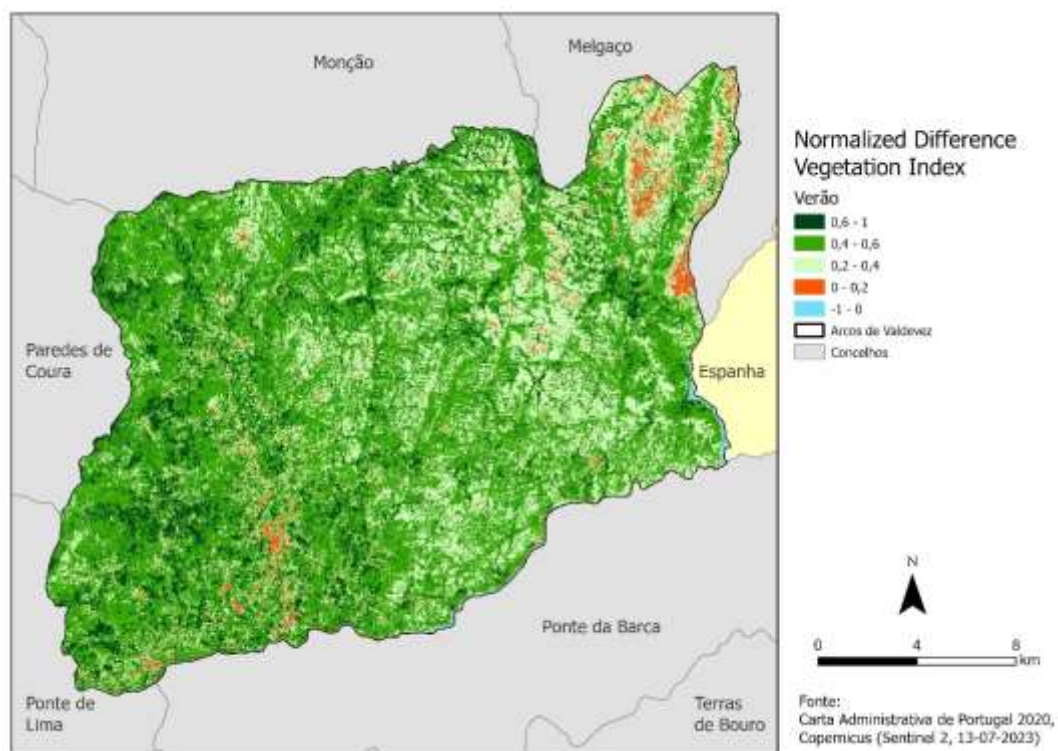


Figura 3- Mapa do NDVI de verão.



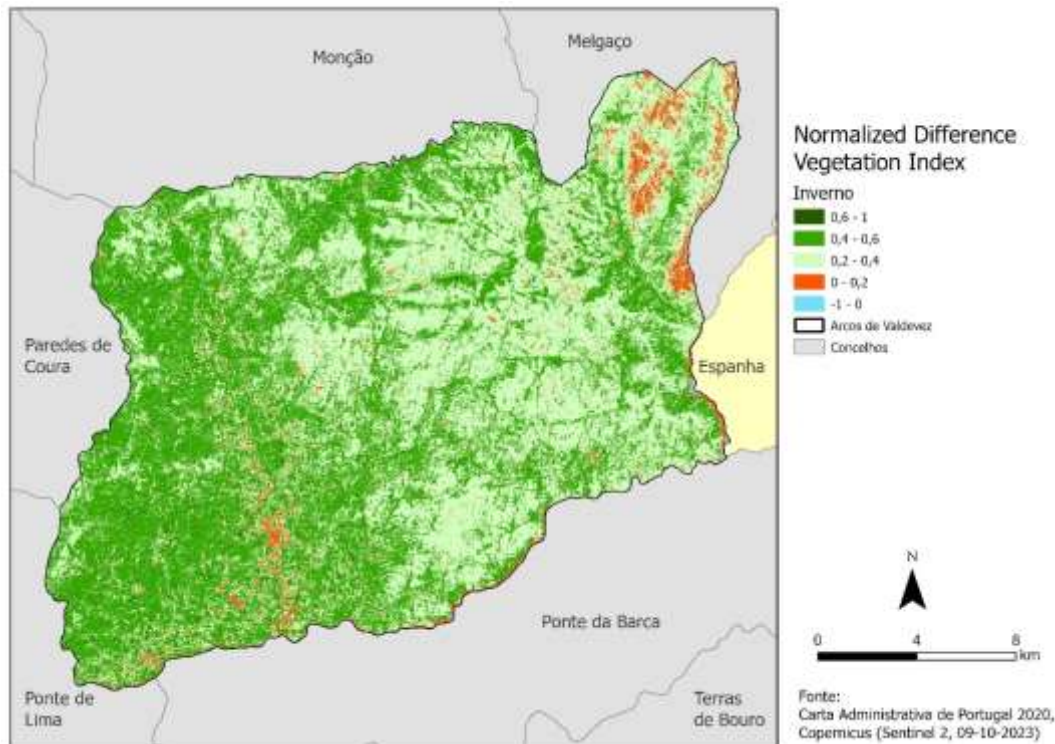


Figura 4- Mapa do NDVI de Inverno

## 4.2- Classificação Supervisionada

A classificação de uma imagem tem como objetivo a substituição da análise visual da imagem por técnicas quantitativas, de maneira a melhorar a identificação dos elementos da imagem. Para a sua realização normalmente é necessária uma análise multiespectral da imagem, bem como a aplicação de regras de decisões estatísticas de forma a identificar qual o tipo de ocupação do solo de cada pixel que compõem a imagem.

As regras podem ter por base um processo baseado nas características espectrais dos pixéis ou o processo baseado nas formas geométricas, no tamanho e tipo de dados (domínio espectral). Geralmente a análise da distribuição dos níveis de cinzento de uma única banda não é o suficiente para a classificação de uma imagem. A utilização do espaço de características n-dimensional é uma técnica que permite caracterizar o conteúdo de uma imagem multiespectral. Os espaços de características podem consistir em diferentes bandas de um sensor ou quaisquer outros valores que possam ser determinados para cada pixel.

Nesta classificação aplicou-se a classificação baseada no pixel, onde se agrupou de forma automática todos os pixéis de uma imagem que estão compreendidos num determinado tipo de ocupação do solo: tecido edificado, massas de água, florestas.

A classificação de uma imagem pode dividir-se em dois tipos, a Classificação supervisionada e não supervisionada. Este trabalho debruça-se sobre a classificação supervisionada de imagens do Sentinel 2. Na classificação supervisionada é necessário a intervenção de um produtor. Na classificação supervisionada, os algoritmos de classificação procedem a uma análise espectral das características dos elementos da imagem e da informação numérica sobre os pixéis das áreas de treino (zonas onde a classe é conhecida) nas diferentes bandas, que posteriormente são usadas para “treinar” o algoritmo que vai fazer um reconhecimento para cada classe das zonas da

imagem em que as propriedades espectrais são semelhantes. Tendo por base esta informação o algoritmo irá proceder a uma classificação da imagem.

O método de classificação utilizado foi o Maximum Likelihood, visto este apresentar a maior percentagem no overall accuracy. O overall accuracy diz-nos de todos os locais de referência a proporção que foi mapeada corretamente. Esta precisão geralmente é expressa em percentagem. Neste trabalho consideramos apenas as classificações que deram o maior overall accuracy, estando este valor sempre acima dos 75%.

Maximum Likelihood Verão:

**Overall accuracy [%] = 94.2365**

Maximum Likelihood inverno:

**Overall accuracy [%] = 99.5164**

#### 4.2.1- Classificação supervisionada da imagem de verão

Após a criação da combinação RGB das três bandas, neste caso a utilizada foi a combinação 7-3-2, foram criadas as áreas de treino, para as quais escolhemos as cores para cada classe, a seguir avaliou-se a separabilidade das classes.

Em seguida à marcação das áreas de treino procedeu-se à execução do método de classificação supervisionada no pixel, onde foi possível conferir que existe um predomínio das classes Matos, Agricultura e Tecido edificado sobre as 7 classes que foram estipuladas durante as áreas de treino. O Resultado presente na figura 5 retrata, bem como se comporta a ocupação do solo da área de estudo visto que consegue demonstrar os focos populacionais e os contrastes entre as áreas agrícolas e os matos.

De seguida um destaque os espaços descobertos ou com pouca vegetação que se encontram nas serras devido aos característicos afloramentos graníticos. No que se refere às Massas de água destacam-se algumas parcelas do Rio Lima e do Rio Vez, quanto aos restantes cursos de água que são de reduzida dimensão e circundados por bastante vegetação, sendo quase impercetível devido à escala de trabalho a que estamos a trabalhar.

Destacam-se as áreas de floresta pela sua percetibilidade. Por outro lado, as áreas industriais encontram-se impercetíveis. Os matos como classe que predomina na área de estudo é bastante percetível, muitas vezes áreas agrícolas estão próximas de matos e devido à escala de trabalho estas tornam-se impercetíveis.

No entanto a imagem não está totalmente correta uma vez que se formos analisar ao pormenor é possível encontrar junto aos afloramentos graníticos tecido edificado o qual não existe nestas zonas, outro erro percetível é nas margens dos rios que são tem áreas classificadas como tecido edificado.

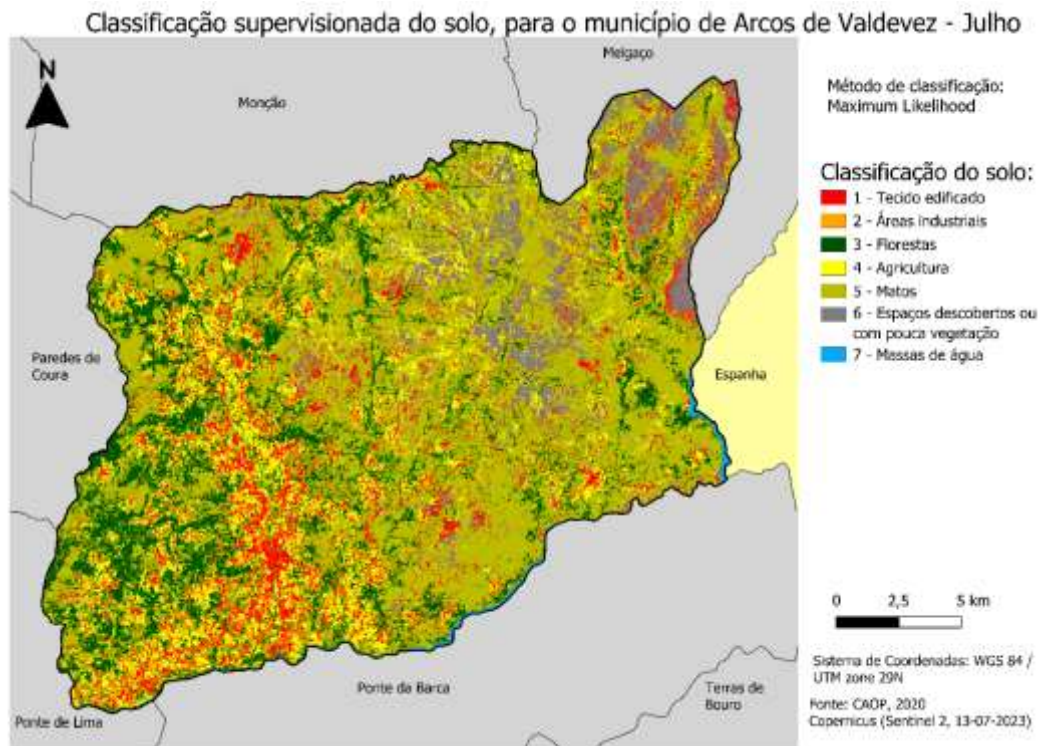


Figura 5- Mapa da classificação supervisionada de verão, pelo método Maximum Likelihood

#### 4.2.2- Classificação supervisionada da imagem de inverno

Após a classificação da imagem de verão foi necessário fazer uma classificação para a imagem de inverno, é possível notar predominância das florestas e matos e a agricultura, no total das 7 classes definidas, estando retratado na figura 6. Nesta classificação também é possível encontrar erros na classificação uma vez que esta marca áreas industriais no alto da serra perto dos afloramentos graníticos, e classifica as massas de água como áreas industriais, florestas e matos, este problema pode ser um erro do plugin ou do próprio programa uma vez que no método minimum distance classificou algumas partes do rio e o Spectral angle Mapping também classifica alguns pixels.

Comparando as classificações de verão e de inverno é possível observar que há uma mudança nas classes predominantes enquanto no verão predominam os matos, a agricultura e o tecido edificado no inverno predominam as florestas os matos e a agricultura podemos ver um aumento das áreas de florestas.

Denota-se também um aumento dos espaços descobertos e com pouca vegetação e das áreas industriais da classificação de verão para a de inverno. As áreas que representam as massas de água diminuíram da classificação de verão para a de inverno. O tecido edificado e a agricultura também tiveram uma diminuição de área, do verão para o inverno. Os matos apesar de serem a classe que predomina nas duas classificações apresenta uma diminuição na área.

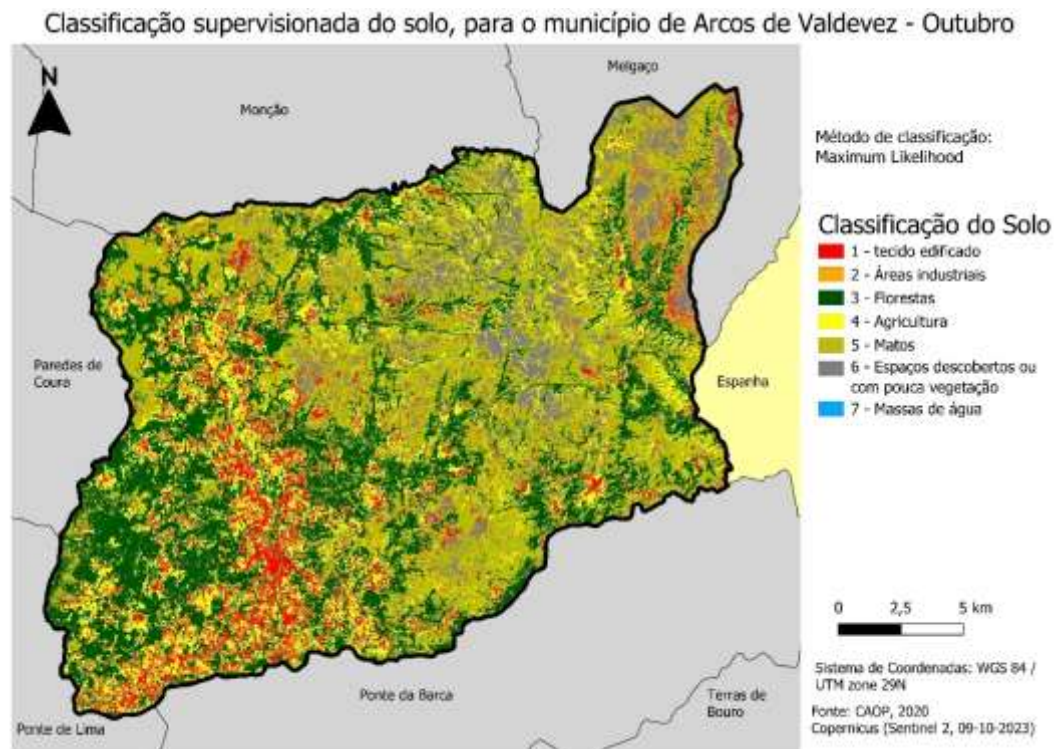


Figura 6- Mapa da classificação supervisionada de inverno, pelo método Maximum Likelihood

### 4.3- Avaliação da Exatidão da imagem

No fim de realizar a classificação supervisionada é preciso verificar o nível de perfeição dos métodos. Para isso é calculada a exatidão, a partir da análise de matrizes de erro ou confusão, sendo importantes para comparar a relação que existe entre os pixéis identificados automaticamente com aqueles criados nas áreas de treino, isto para cada classe. Os valores que podemos obter ficam entre os 0 e os 100%, mas apenas valores acima de 75% são considerados como uma boa classificação. Para avaliar o resultado é importante verificar as tabelas de erro, onde vários valores são visíveis, como os totais de cada linha que representam os produtos da classificação. Enquanto os valores das colunas dizem respeito aos dados de referência (verdade do terreno), e por fim os valores na diagonal são os elementos classificados corretamente. Todos os valores fora da diagonal são os erros podendo ser de comissão ou de omissão. A fórmula de calculo da exatidão global é a seguinte:

$$\text{Exatidão Global} = \frac{\sum \text{Elementos da diagonal}}{\text{Número total de amostras}}$$

Para avaliar a exatidão existe um outro parâmetro que é utilizado para analisar os valores obtidos pela classificação é a estatística Kappa. Este não vai ser utilizado para esta avaliação uma vez que não foi possível calcular. Definindo-se pela medida da diferença entre a classificação supervisionada e uma classificação completamente aleatória, tendo esta como resultado a concordância real entre os dados. Os valores desta classificação encontram-se entre 0 e 1, se o valor for inferior a 0,4 a classificação é considerada incorreta, entre 0,4 e 0,75 é considerada média, mas não muito fiável. E por fim os valores superiores a 0,75 definem-se como uma

concordância muito boa, quer dizer que se poderia usar para fazer um do uso e ocupação do solo. A fórmula que se aplica para o cálculo é a seguinte:

$$Kappa = \frac{Exatidão\ Observada - Concordância\ hipotética}{1 - Concordância\ hipotética}$$

Nas classificações que realizamos só foram consideramos apenas as que apresentaram maior overral accuracy onde o valor mínimo que era necessário é 75%. Para a classificação da imagem de verão o overral accuracy foi de 94.2365% e na classificação da imagem de inverno obtivemos o valor de 99.5164%. De modo a obter estes valores foi necessário fazer novamente as áreas de treino com o objetivo de diminuir os erros dos pixels com semelhanças de valor.

#### **4.3.1- Precisão geral da classificação supervisionada de verão**

A figura 7 apresenta a matriz de erro relativa á classificação de verão, é possível observar que tivemos pixels mal classificados nas classes: tecido edificado, florestas, agricultura, matos, espaços descobertos ou com pouca vegetação, áreas industriais e massas de água. No tecido edificado foram mal classificados pelo produtor 2 pixels, enquanto o algoritmo confundiu 8 pixels com matos, 1 com espaços descobertos e 1 com massas de água obtendo uma exatidão de 98,8% para o produtor e do utilizador de 94,4% apresentando um erro de omissão.

Nas florestas foram classificados mal pelo produtor 4 pixels na agricultura e 70 nos matos e pelo utilizador forma 405 com matos e 5 com massas de água, com isto temos uma exatidão de 95,4% para o produtor e 78,8% para o utilizador, apresentando assim um erro de omissão. Na classe agricultura foram classificados pelo produtor 8 pixels como matos, enquanto o utilizador classificou 21 pixels como matos e 4 como florestas, apresentando assim uma exatidão de 98,1 % para o produtor e 94,4% para o utilizador apresentando um erro de omissão.

Nos matos foram classificados pelo produtor 8 pixels com tecido edificado, 405 como florestas, 2 como agricultura e 13 como espaços descobertos ou com pouca vegetação, em contrapartida o utilizador classificou 70 pixels como florestas, 8 como agricultura e um como massas de água, apresentando assim uma exatidão de 90,5% enquanto o utilizador 98,1%, apresentando um erro de comissão.

Os espaços descobertos ou com pouca vegetação apresentam 1 pixel classificado como tecido edificado pelo produtor, em contrapartida o utilizador apresenta 13 pixels classificados como matos com isto obtemos uma exatidão de 99,9% para o produtor enquanto o utilizador 99,1%, apresentando um erro de omissão.

Nas áreas industriais o produtor classificou tudo corretamente enquanto o utilizador classificou 2 pixels como tecido edificado, alcançando assim uma exatidão de 100% para o produtor e 99,6% para o utilizador, apresentando um erro de omissão.

As massas de água apresentam classificados pelo produtor 5 pixels como florestas, 1 como tecido edificado e 1 como matos já o utilizador não classificou nenhum pixel erradamente, conseguimos assim observar uma exatidão de 98,7% para o produtor e 100% para o utilizador, apresentando um erro de comissão.



V_Classified	Tecido edificado	Áreas industriais	Florestas	Agricultura	Matos	Espaços descobertos	Massas de água	total	Exatidão
Tecido edificado	167	0	0	0	8	1	1	177	94,4
Áreas industriais	2	504	0	0	0	0	0	506	99,6
Florestas	0	0	1522	0	405	0	5	1932	78,8
Agricultura	0	0	4	403	21	0	0	428	94,2
Matos	0	0	70	8	4260	0	1	4339	98,2
Espaços descobertos	0	0	0	0	13	1427	0	1440	99,1
Massas de água	0	0	0	0	0	0	530	530	100
total	169	504	1596	411	4707	1428	537	9352	
exatidão	98,8	100,0	95,4	98,1	90,5	99,9	98,7		

#### 4.3.1- Precisão geral da classificação supervisionada de Inverno.

Na figura 8 está representada a matriz de erro relativa á classificação de inverno, é possível observar que tivemos pixéis mal classificados em todas as 7 classes. No tecido edificado o produtor não classificou mal nenhum pixel, enquanto o algoritmo confundiu 1 pixel com áreas industriais e 1 com espaços descobertos, obtendo uma exatidão de 100% para o produtor e do utilizador de 98,7%, apresentando um erro de omissão.

Nas florestas foram classificados mal pelo produtor 4 pixéis na agricultura e 3 nos matos e pelo utilizador não foram classificados erradamente nenhum pixel, com isto temos uma exatidão de 98,8% para o produtor e 100% para o utilizador, apresentando um erro de comissão. Na classe agricultura não foram classificados erradamente nenhum pixel, enquanto o utilizador classificou 4 pixéis como floresta, apresentando assim uma exatidão de 100 % para o produtor e 98,5% para o utilizador, apresentando um erro de omissão.

Nos matos não foram classificados erradamente nenhum pixel pelo produtor, em contrapartida o utilizador classificou 3 pixéis como florestas, apresentando assim o produtor uma exatidão de 100% enquanto o utilizador 99,7%, apresentando um erro de omissão.

Os espaços descobertos ou com pouca vegetação apresentam 1 pixel classificado como tecido edificado e 6 classificados como áreas industriais pelo produtor, em contrapartida o utilizador não apresenta nenhum pixel classificado erradamente com isto obtemos uma exatidão de 99,2% para o produtor enquanto o utilizador 100% apresentando um erro de comissão.

Nas áreas industriais o produtor classificou 1 pixel como tecido edificado enquanto o utilizador classificou 2 pixéis como massas de água e 6 como espaços descobertos, alcançando assim uma exatidão de 99,8% para o produtor e 98,4% para o utilizador, apresentando um erro de omissão.

As massas de água apresentam não apresenta nenhum pixel classificado apresentando apenas um erro de 2 pixeis classificados como áreas industriais, apresenta um valor de exatidão de 0% tanto para o produtor como para o utilizador.

V_Classified	Tecido edificado	Áreas industriais	Florestas	Agricultura	Matos	Espaços descobertos	Massas de água	total	exatidão
Tecido edificado	151	1	0	0	0	1	0	153	98,7
Áreas industriais	0	488	0	0	0	6	2	496	98,4
Florestas	0	0	601	0	0	0	0	601	100,0
Agricultura	0	0	4	262	0	0	0	266	98,5
Matos	0	0	3	0	1109	0	0	1112	99,7
Espaços descobertos	0	0	0	0	0	887	0	887	100,0
Massas de água	0	0	0	0	0	0	0	0	0,0
total	151	489	608	262	1109	894	2	3515	
exatidão	100,0	99,8	98,8	100,0	100,0	99,2	0,0		

## Conclusão:

No fim de observar os aspetos abordados, pode-se concluir que depois da realização deste trabalho comparativo entre as imagens, entre os índices realizados e as classificações, permitiu adquirir conhecimentos práticos e teóricos sobre como analisar o terreno através da deteção remota.

Das análises aos índices ambientais foi possível perceber que existe uma grande diferença entre duas épocas distintas do ano, bem como as disparidades nos valores dos dados obtidos. Como as diferentes situações climáticas e níveis de humidade podem levar o NDVI a sofrer alterações nos seus valores. Podendo estes estar relacionados com o nível de precipitação e humidade do solo pois em anos com altos valores destes dois indicadores a refletância é menor dado a quantidade de água existente. Pelo contrário também se pode concluir que em anos de onde se verifica défices hídricos que há um aumento dos valores da refletância quando associado ao solo seco reflete mais. No caso da vegetação, quando afetado por fatores hídricos, dados que não conseguem realizar o processo de fotossíntese (stress hídrico) os valores de refletância para a banda NIR são inferiores.

No que diz respeito à classificação realizada pode-se afirmar que as classes definidas estão diretamente relacionadas com a tipologia de ocupação do solo. Durante o processo foram detetados erros derivados das semelhanças espectrais de certos píxeis correspondentes a classes diferentes principalmente apreendidos na comparação entre resultados.

Quanto aos erros identificados e confirmados pelas matrizes de erro, permitira-nos adquirir uma descrição das classes com maior ou menor exatidão e que demonstram ao mesmo tempo qual dos intervenientes foi responsável pelos erros.

Este trabalho foi muito limitado pelo software QGIS uma vez que não podemos aplicar os conhecimentos adquiridos durante a aula não podendo criar macro classes pois estas induziam

erro na classificação. O programa dava erros constantemente impedindo o trabalho e por fim não assumiu as áreas de treino criadas para a imagem de inverno na classes massas de água uma vez que não classifica os locais que são rio como uma massa de água, nos mapas elaborados para os outros dois métodos já é possível ver alguns pixéis classificados mas não a totalidade.

## Bibliografia

Jensen, J.R. (2006) Remote Sensing of the Environment: Na Earth Resource Perspective. 2nd ed Prentice Hall, New Jersey.

## Anexos:

